

# Statistik

CH.4 - Zweidimensionale Verteilungen

2026 || Prof. Dr. Buchwitz, Sommer, Henke

Wir geben Impulse


- Erweiterung der Streuungsbetrachtung von einem auf zwei Merkmale
- Erkennen des Zusammenhangs von Streuung mehrerer Variablen und (linearem) Zusammenhang
- Diskussion und Betrachtung relevanter Maßzahlen zur Messung von Zusammenhängen

1 Streuung und Streudiagramme

2 Kovarianz

3 Korrelation

## Rekapitulation: Streuung



## Ausgangspunkt:

- Jede statistische Einheit einer Grundgesamtheit trägt eine Vielzahl von Merkmalen.
- In diesem Kapitel werden zwei Merkmale gleichzeitig untersucht.
- Bei der Darstellung und Analyse von Abhängigkeiten zwischen Variablen muss das Skalenniveau berücksichtigt werden.


## Beispiel:

- Studierende
  - ▶ Beispiel: Körpergröße und Gewicht → Streudiagramm
  - ▶ Beispiel: Geschlecht und Studiengang → Kontingenztafel
- Kraftfahrzeuge
  - ▶ Beispiel: Höchstgeschwindigkeit und Motorleistung
  - ▶ Beispiel: Kraftstoffverbrauch und Getriebeart (Manuell/Automatik)

# Beispiel: Streudiagramm

| Größe (m) | Gewicht (kg) |
|-----------|--------------|
| 1.63      | 68           |
| 1.51      | 81           |
| 1.56      | 72           |
| 1.95      | 128          |
| 1.80      | 60           |
| 1.79      | 64           |
| 1.78      | 94           |
| 1.68      | 62           |
| 1.89      | 109          |
| 1.61      | 75           |
| 1.89      | 76           |
| 1.97      | 126          |
| 1.61      | 98           |
| 1.57      | 71           |
| 1.83      | 66           |
| 1.80      | 111          |
| 1.72      | 89           |
| 1.52      | 76           |
| 1.54      | 45           |

R-Befehl: `plot()`




1 Streuung und Streudiagramme

2 Kovarianz

3 Korrelation

Gewicht (kg) vs. Körpergröße (cm)





## Aufgabe: Bestimmen des Vorzeichens

- $y_i - \bar{y}$  ist die Differenz jeder Beobachtung  $y_i$  vom arithmetischen Mittel der abhängigen Variablen
- $x_i - \bar{x}$  ist die Abweichung  $x_i$  vom arithmetischen Mittel des Prädiktors
- $(y_i - \bar{y})(x_i - \bar{x})$  ist das Produkt der vorherigen beiden Größen

| Quadrant         | $y_i - \bar{y}$ | $x_i - \bar{x}$ | $(y_i - \bar{y})(x_i - \bar{x})$ |
|------------------|-----------------|-----------------|----------------------------------|
| 1 (oben rechts)  |                 |                 |                                  |
| 2 (oben links)   |                 |                 |                                  |
| 3 (unten links)  |                 |                 |                                  |
| 4 (unten rechts) |                 |                 |                                  |

## Positiver Zusammenhang

- Wenn der Zusammenhang zwischen  $Y$  und  $X$  **positiv** ist (also wenn  $X$  größer wird, dann wird auch  $Y$  größer), dann sind mehr Datenpunkte im ersten und dritten Quadranten als im zweiten und vierten.
- Die Summe der Elemente in der letzten Spalte der vorherigen Tabelle ist dann mit großer Wahrscheinlichkeit positiv, also  $\text{Cov}(Y, X) > 0$ .

## Positiver Zusammenhang

- Wenn der Zusammenhang zwischen Y und X **positiv** ist (also wenn X größer wird, dann wird auch Y größer), dann sind mehr Datenpunkte im ersten und dritten Quadranten als im zweiten und vierten.
- Die Summe der Elemente in der letzten Spalte der vorherigen Tabelle ist dann mit großer Wahrscheinlichkeit positiv, also  $\text{Cov}(Y, X) > 0$ .

## Negativer Zusammenhang

- Wenn der lineare Zusammenhang zwischen Y und X **negativ** ist (z.B. wenn X sinkt, steigt Y), dann befinden sich mehr Datenpunkte im zweiten und vierten Quadranten als im ersten und dritten.
- Die Summe der Elemente in der letzten Spalte der vorherigen Tabelle ist dann mit großer Wahrscheinlichkeit negativ, also  $\text{Cov}(Y, X) < 0$ .

$$s_{XY} = \text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})$$

- Die oben stehende Formeln gibt die Kovarianz zwischen X und Y an.
- Das Vorzeichen der Kovarianz ist ein Indikator für die Richtung eines bestehenden **linearen** Zusammenhangs zwischen Y und X.
- Die Kovarianz erlaubt es nicht, Aussagen über die Stärke eines Zusammenhangs zu treffen.
- Die Größe der Kovarianz ist abhängig von der zugrundeliegenden Einheit. Einheitenwechsel (z.B. von Euro zu TEuro) führen zu einer Wertveränderung.
- **R-Befehl:** `cov()`

1 Streuung und Streudiagramme

2 Kovarianz

3 Korrelation

$$\text{Cor}(Y, X) = \frac{1}{n-1} \sum_{i=1}^n \left( \frac{y_i - \bar{y}}{s_y} \right) \left( \frac{x_i - \bar{x}}{s_x} \right) = \frac{\text{Cov}(Y, X)}{s_y s_x} = \frac{s_{xy}}{s_x \cdot s_y}$$

- Der Korrelationskoeffizient ist ein Maß für die Stärke des linearen Zusammenhangs.
- Im Unterschied zur Kovarianz ist  $\text{Cor}(Y, X)$  nicht skalenabhängig und erlaubt die Einschätzung von Stärke und Richtung eines linearen Zusammenhangs.
- **R-Befehl:** `cor()`

$\text{Cor}(Y, X) = 0$  bedeutet nicht, dass es zwischen  $X$  und  $Y$  keinen Zusammenhang gibt.

- 1 Wertebereich:  $-1 \leq r_{XY} \leq 1$
- 2 Ist  $r_{XY} = 0$ , so sind  $X$  und  $Y$  nicht korreliert (unkorreliert).
- 3 Ist  $r_{XY} > 0$ , so sind  $X$  und  $Y$  gleichläufig (gleichsinnig) korreliert.
- 4 Ist  $r_{XY} < 0$ , so sind  $X$  und  $Y$  gegenläufig (ungleichsinnig) korreliert.
- 5 Je größer  $|r_{XY}|$  ist, desto stärker ist die Korrelation zwischen  $X$  and  $Y$ .

**Scheinkorrelation:** obwohl ein großer Wert des Korrelationskoeffizienten zwischen  $X$  und  $Y$  besteht, liegt kein *ursächlicher* (und/oder sachlogischer) Zusammenhang zwischen  $X$  und  $Y$  vor.

## Beispiel


Zusammenhang zwischen Kindergeburten und der Anzahl der Storchpaare, die sich in einer Region ansiedeln.



# Scheinkorrelation

## US Spending on science, space, and technology and Suicides by hangig, strangulation and suffocation

korrelation: 0.9921



■ Weitere Beispiele unter: <http://tylervigen.com/spurious-correlations>

- Welche Darstellungsmöglichkeiten gibt es für zweidimensionale Daten?
- Bedeutet ein Korrelationskoeffizient nah bei 1, dass ein sachlicher Zusammenhang zwischen den untersuchten Merkmalen besteht?
- Wie ist ein Korrelationskoeffizient nah bei -1 zu interpretieren?