Fachhochschule Südwestfalen
University of Applied Sciences

# Statistik

CH.4 - Zweidimensionale Verteilungen

2026 || Prof. Dr. Buchwitz, Sommer, Henke

Wir geben Impulse

# Lernziele

- Erweiterung der Streuungsbetrachtung von einem auf zwei Merkmale
- Erkennen des Zusammenhangs von Streuung mehrerer Variablen und (linearem) Zusammenhang
- Diskussion und Betrachtung relevanter MAßzahlen zur Messung von Zusammenhängen

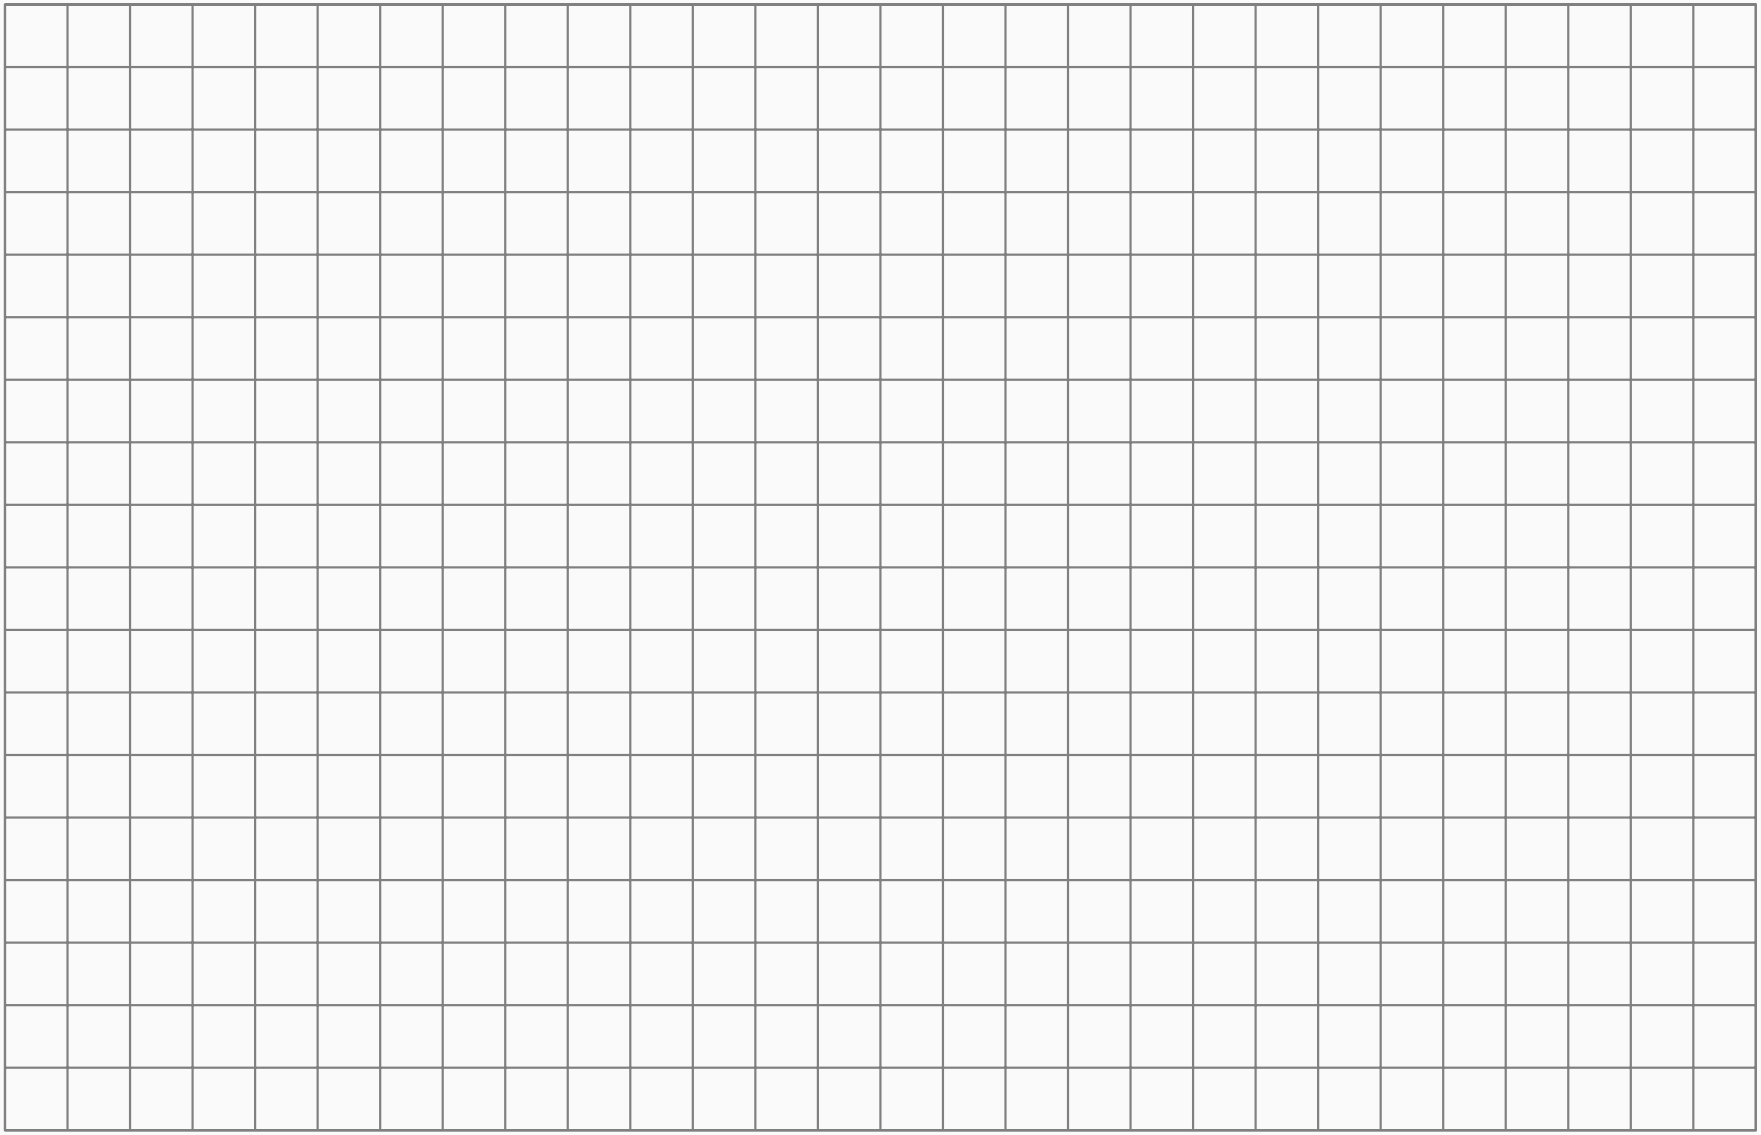
# Inhaltsübersicht

1 Streuung und Streudiagramme

2 Kovarianz

3 Korrelation

# Rekapitulation: Streuung



# Zweidimensionale Verteilungen

**Ausgangspunkt:**

- Jede statistische Einheit einer Grundgesamtheit trägt eine Vielzahl von Merkmalen.
- In diesem Kapitel werden zwei Merkmale gleichzeitig untersucht.
- Bei der Darstellung und Analyse von Abhängigkeiten zwischen Variablen muss das Skalenniveau berücksichtigt werden.

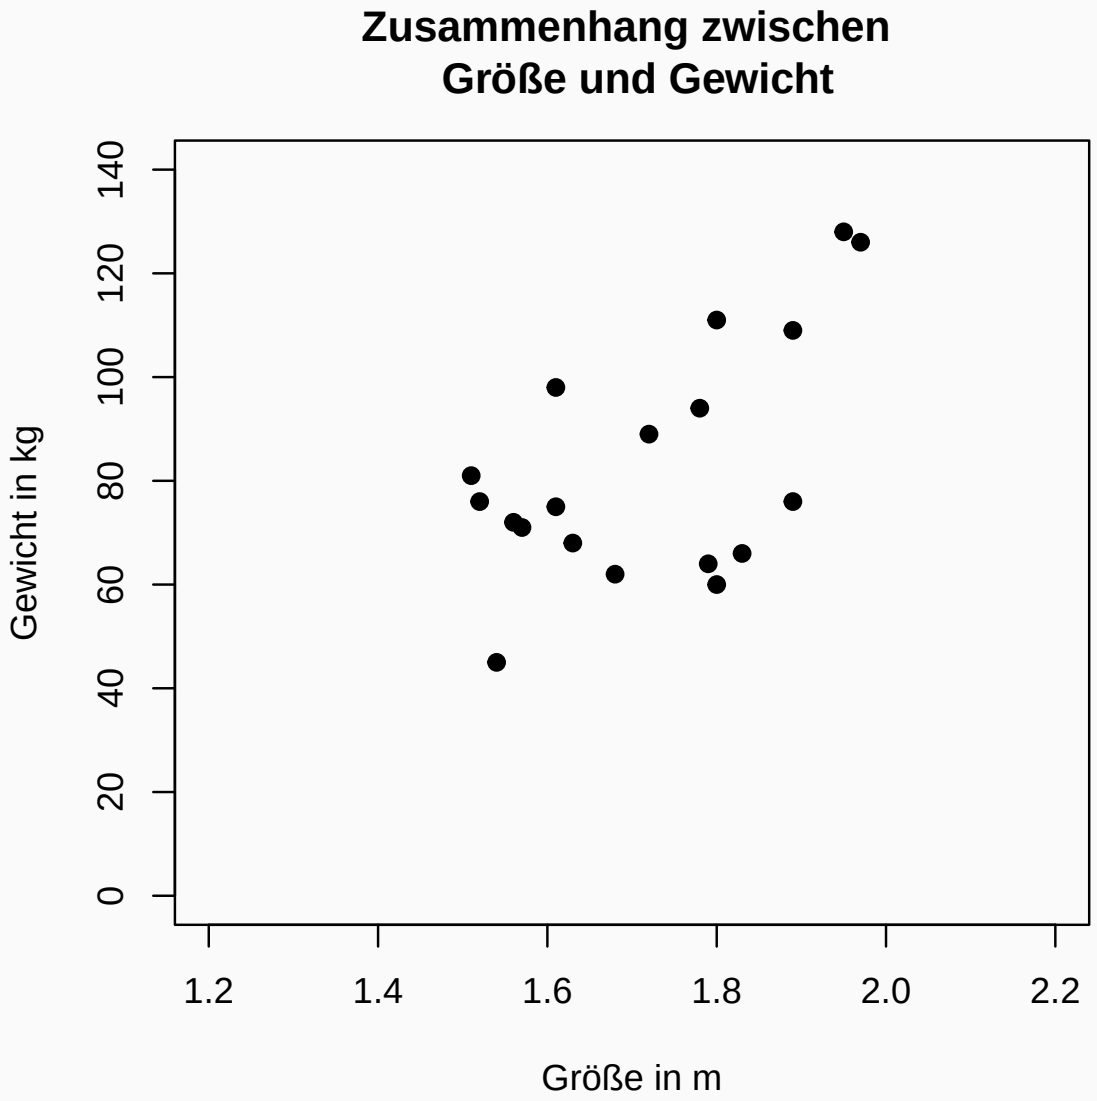
**Beispiel:**

- Studierende
  - Beispiel: Körpergröße und Gewicht $\rightarrow$ Streudiagramm
  - Beispiel: Geschlecht und Studiengang $\rightarrow$ Kontingenztafel
- Kraftfahrzeuge
  - Beispiel: Höchstgeschwindigkeit und Motorleistung
  - Beispiel: Kraftstoffverbrauch und Getriebeart (Manuell/Automatik)

# Beispiel: Streudiagramm

| Größe (m) | Gewicht (kg) |
|---|---|
| 1.63 | 68 |
| 1.51 | 81 |
| 1.56 | 72 |
| 1.95 | 128 |
| 1.80 | 60 |
| 1.79 | 64 |
| 1.78 | 94 |
| 1.68 | 62 |
| 1.89 | 109 |
| 1.61 | 75 |
| 1.89 | 76 |
| 1.97 | 126 |
| 1.61 | 98 |
| 1.57 | 71 |
| 1.83 | 66 |
| 1.80 | 111 |
| 1.72 | 89 |
| 1.52 | 76 |
| 1.54 | 45 |

**R-Befehl:** `plot()`



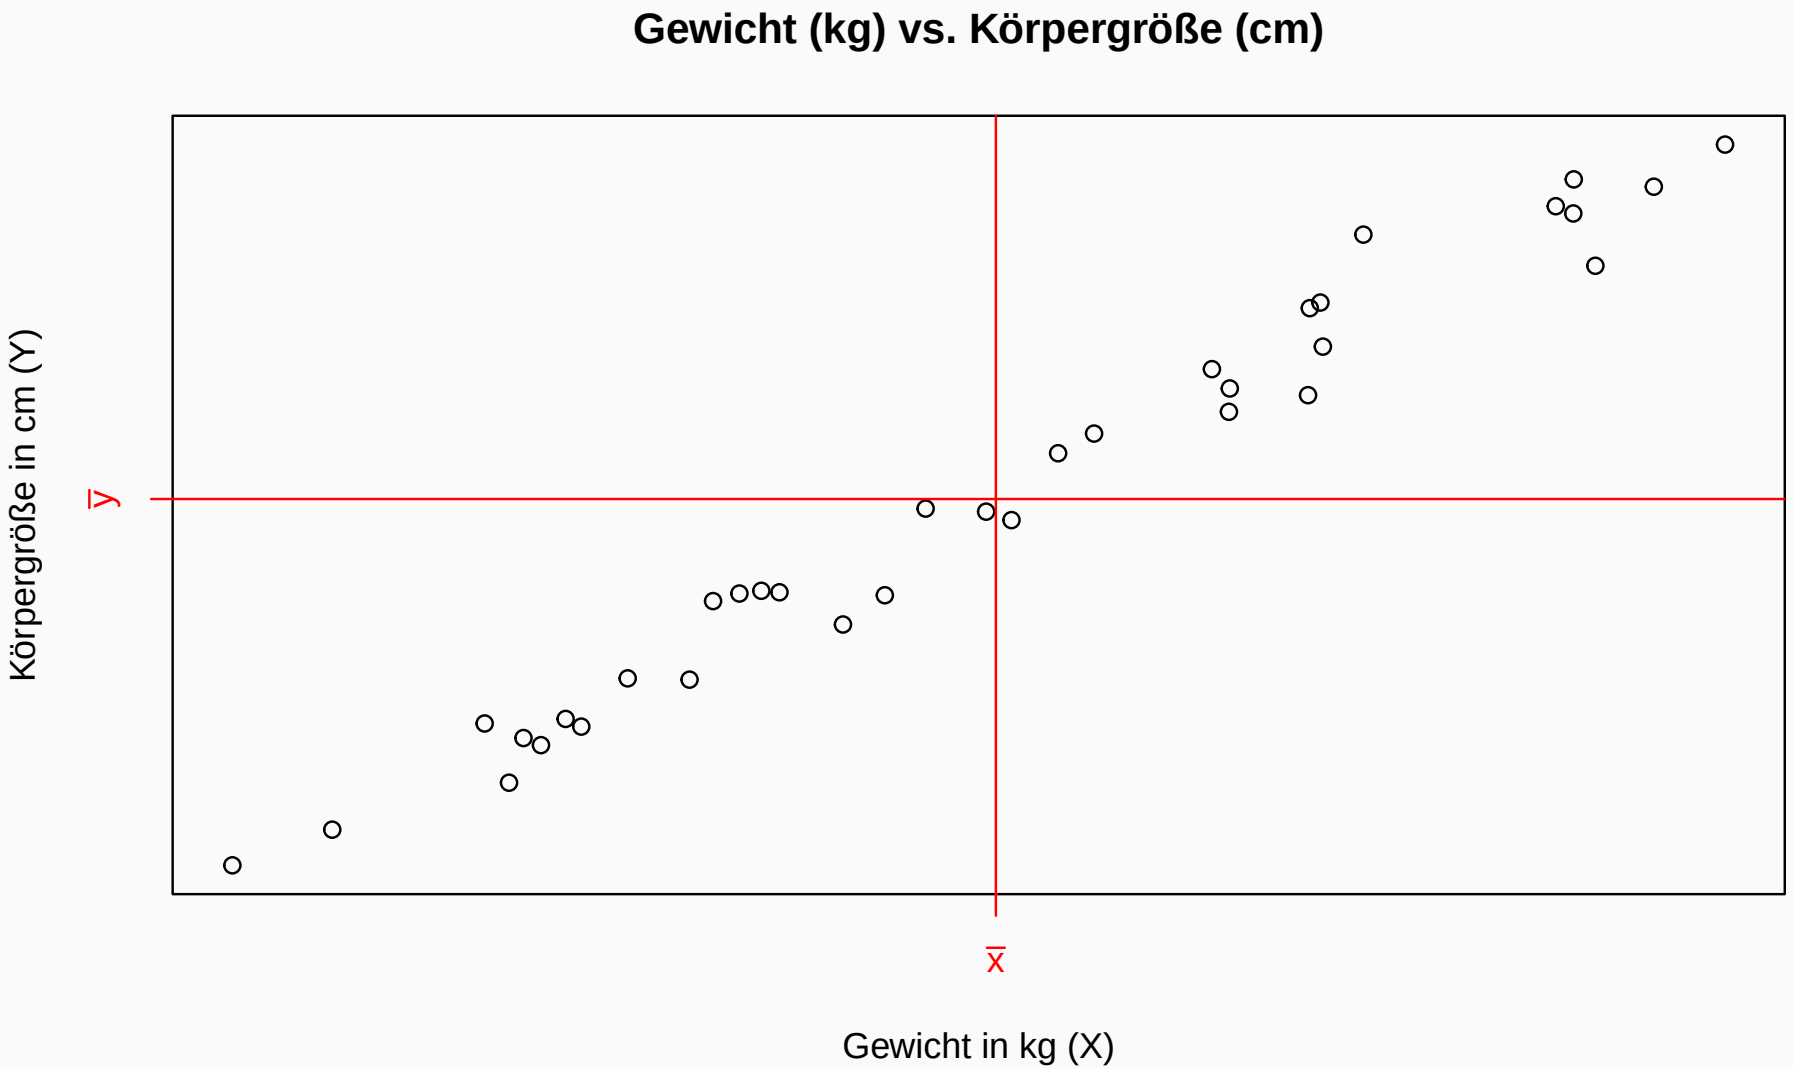
# Inhaltsübersicht

1 Streuung und Streudiagramme

2 Kovarianz

3 Korrelation

# Kovarianz


Gewicht (kg) vs. Körpergröße (cm)
Körpergröße in cm (Y)
$\bar{y}$
$\bar{x}$
Gewicht in kg (X)

# Kovarianz

**Aufgabe: Bestimmen des Vorzeichens**

- $y_i - \bar{y}$ ist die Differenz jeder Beobachtung $y_i$ vom arithmetischen Mittel der abhängigen Variablen
- $x_i - \bar{x}$ ist die Abweichung $x_i$ vom arithmetischen Mittel des Prädiktors
- $(y_i - \bar{y})(x_i - \bar{x})$ ist das Produkt der vorherigen beiden Größen

| Quadrant | $y_i -\bar{y}$ | $x_i - \bar{x}$ | $(y_i - \bar{y})(x_i - \bar{x})$ |
|---|---|---|---|
| 1 (oben rechts) | | | |
| 2 (oben links) | | | |
| 3 (unten links) | | | |
| 4 (unten rechts) | | | |

# Kovarianz

## Positiver Zusammenhang

- Wenn der Zusammenhang zwischen $Y$ und $X$ **positiv** ist (also wenn $X$ größer wird, dann wird auch $Y$ größer), dann sind mehr Datenpunkte im ersten und dritten Quadranten als im zweiten und vierten.
- Die Summe der Elemente in der letzten Spalte der vorherigen Tabelle ist dann mit großer Wahrscheinlichkeit positiv, also $Cov(Y, X) > 0$.

# Kovarianz

## Positiver Zusammenhang

- Wenn der Zusammenhang zwischen $Y$ und $X$ **positiv** ist (also wenn $X$ größer wird, dann wird auch $Y$ größer), dann sind mehr Datenpunkte im ersten und dritten Quadranten als im zweiten und vierten.
- Die Summe der Elemente in der letzten Spalte der vorherigen Tabelle ist dann mit großer Wahrscheinlichkeit positiv, also $Cov(Y, X) > 0$.

## Negativer Zusammenhang

- Wenn der lineare Zusammenhang zwischen $Y$ und $X$ **negativ** ist (z.B. wenn $X$ sinkt, steigt $Y$), dann befinden sich mehr Datenpunkte im zweiten und vierten Quadranten als im ersten und dritten.
- Die Summe der Elemente in der letzten Spalte der vorherigen Tabelle ist dann mit großer Wahrscheinlichkeit negativ, also $Cov(Y, X) < 0$.

# Kovarianz

$$s_{XY} = Cov(X, Y) = \frac{1}{n-1} \sum_{i=1}^{n} (y_i - \bar{y})(x_i - \bar{x})$$

- Die oben stehende Formeln gibt die Kovarianz zwischen $X$ und $Y$ an.
- Das Vorzeichen der Kovarianz ist ein Indikator für die Richtung eines bestehenden **linearen** Zusammenhangs zwischen $Y$ und $X$.
- Die Kovarianz erlaubt es nicht, Aussagen über die Stärke eines Zusammenhangs zu treffen.
- Die Größe der Kovarianz ist abhängig von der zugrundeliegenden Einheit. Einheitenwechsel (z.B. von Euro zu TEuro) führen zu einer Wertveränderung.
- **R-Befehl:** `cov()`

# Inhaltsübersicht

1 Streuung und Streudiagramme

2 Kovarianz

3 Korrelation

# Korrelationskoeffizient

$$Cor(Y, X) = \frac{1}{n-1} \sum_{i=1}^{n} (\frac{y_i - \bar{y}}{s_y})(\frac{x_i - \bar{x}}{s_x}) = \frac{Cov(Y, X)}{s_y s_x} = \frac{s_{XY}}{s_x \cdot s_y}$$

- Der Korrelationskoeffizient ist ein Maß für die Stärke des linearen Zusammenhangs.
- Im Unterschied zur Kovarianz ist $Cor(Y, X)$ nicht skalenabhängig und erlaubt die Einschätzung von Stärke und Richtung eines linearen Zusammenhangs.
- **R-Befehl:** `cor()`

$Cor(Y, X) = 0$ bedeutet nicht, dass es zwischen $X$ und $Y$ keinen Zusammenhang gibt.

# Eigenschaften

1. Wertebereich: $-1 \leq r_{XY} \leq 1$
2. Ist $r_{XY} = 0$, so sind $X$ und $Y$ nicht korreliert (unkorreliert).
3. Ist $r_{XY} > 0$, so sind $X$ und $Y$ gleichläufig (gleichsinnig) korreliert.
4. Ist $r_{XY} < 0$, so sind $X$ und $Y$ gegenläufig (ungleichsinnig) korreliert.
5. Je größer $|r_{XY}|$ ist, desto stärker ist die Korrelation zwischen $X$ and $Y$.

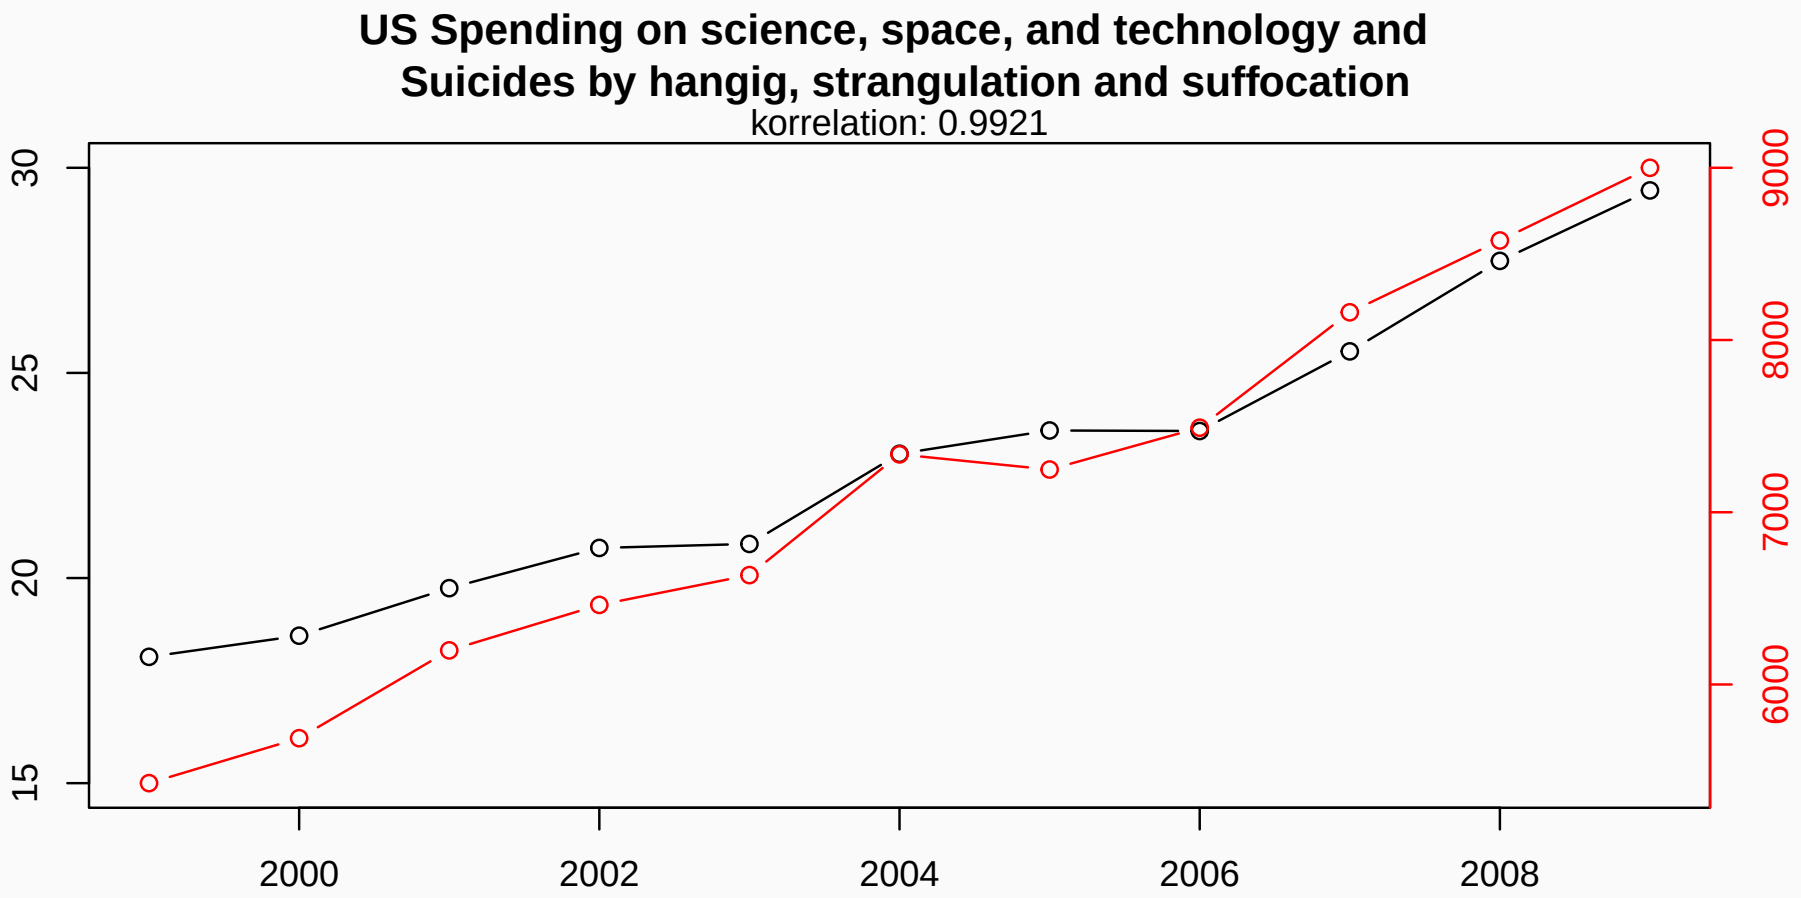
# Scheinkorrelation

**Scheinkorrelation:** obwohl ein großer Wert des Korrelationskoeffizienten zwischen *X* und *Y* besteht, liegt kein *ursächlicher* (und/oder sachlogischer) Zusammenhang zwischen *X* und *Y* vor.

**Beispiel**

Zusammenhang zwischen Kindergeburten und der Anzahl der Storchenpaare, die sich in einer Region ansiedeln.

# Scheinkorrelation




- Weitere Beispiele unter: `http://tylervigen.com/spurious-correlations`

# Verständnisfragen

- Welche Darstellungsmöglichkeiten gibt es für zweidimensionale Daten?
- Bedeutet ein Korrelationskoeffizient nah bei 1, dass ein sachlicher Zusammenhang zwischen den untersuchten Merkmalen besteht?
- Wie ist ein Korrelationskoeffizient nah bei -1 zu interpretieren?